

Generowanie obrazów MRI metodą ewolucji w przestrzeni latentnej GAN

Jan Bassa, Magdalena Dzik

Czerwiec 2026

1 Wstęp

Głównym celem projektu jest realizacja sterowanego generowania obrazów medycznych rezonansu magnetycznego (MRI) mózgu przy wykorzystaniu połączenia bezwarunkowego modelu generatywnego DCGAN oraz algorytmu genetycznego optymalizującego wektory w przestrzeni latentnej.

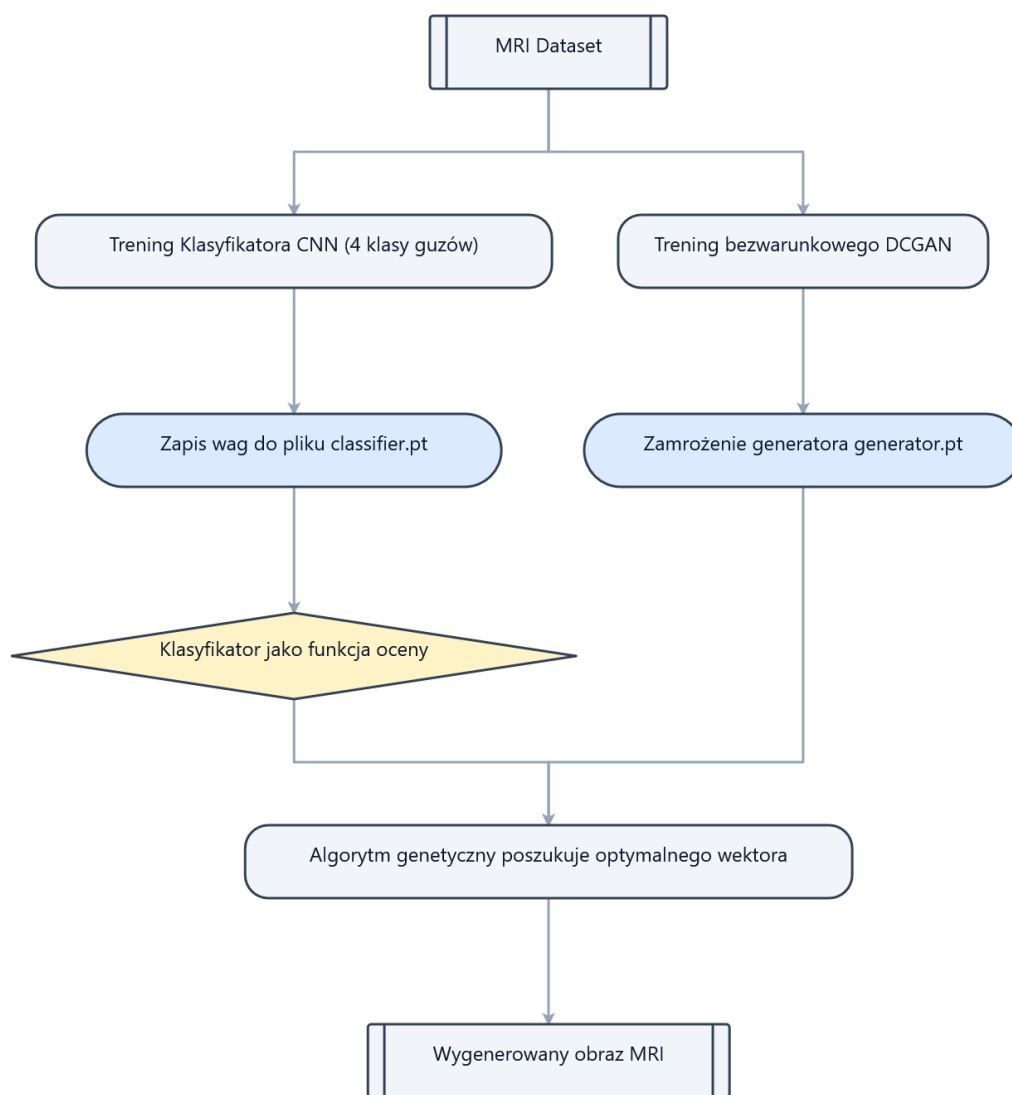
Tradycyjny model DCGAN uczy się rozkładu danych bezwarunkowo. Oznacza to, że generuje losowe obrazy MRI z poznanej przestrzeni, bez możliwości bezpośredniego wskazania, jaki konkretnie typ tkanki lub patologii ma się znaleźć na wyjściu. Niniejszy projekt rozwiązuje ten problem poprzez zastosowanie algorytmu genetycznego działającego bezpośrednio w przestrzeni latentnej zamrożonego generatora. Wykorzystując wcześniej przeszkolony klasyfikator CNN jako funkcję oceny, algorytm genetyczny poszukuje takiego wektora latentnego z , którego obraz po przejściu przez generator $G(z)$ zostanie sklasyfikowany przez sieć CNN jako zadana patologia z jak najwyższym prawdopodobieństwem. Dzięki temu ewolucja potrafi efektywnie wyciąć w ciągłej przestrzeni latentnej obszary odpowiadające konkretnym klasom medycznym, oferując mechanizm sterowania generatorem bez konieczności kosztownego i skomplikowanego treningu warunkowego.

2 Architektura systemu

Cały potok przetwarzania zarządzany przez skrypt główny składa się z trzech niezależnych etapów, których wagi i wyniki pośrednie są automatycznie zapisywane w katalogu wynikowym.

2.1 Etap 1: Trening klasyfikatora CNN

Klasyfikatorem jest sieć splotowa odpowiedzialna za rozpoznawanie czterech klas obrazów MRI ze zbioru BRISC2025. System ten analizuje etykietowane dane medyczne i uczy się identyfikować cechy charakterystyczne dla czterech różnych scenariuszy klinicznych: trzech typów guzów oraz zdrowej tkanki. Wynikiem tego etapu jest model klasyfikacyjny, który potrafi przypisać nowemu obrazowi etykietę diagnostyczną z określonym prawdopodobieństwem.



Rysunek 1: Potok przetwarzania

2.2 Etap 2: Trening bezwarunkowego DCGAN

Równolegle rozwijany jest model generatywny. Celem tego etapu jest nauczenie modelu zasad tworzenia syntetycznych, ale realistycznych obrazów MRI mózgu. Model ten uczy się analizując duży zbiór obrazów treningowych bez etykiet, starając się naśladować ich strukturę. Po zakończeniu treningu generator zostaje zamrożony. Oznacza to, że utrwala swoją zdolność do tworzenia struktur anatomicznych mózgu, ale nie potrafi jeszcze celowo wygenerować konkretnego schorzenia.

2.3 Etap 3: Algorytm genetyczny w przestrzeni latentnej

Algorytm genetyczny służy jako poszukiwacz optymalnego wektora latentnego z . Iteracyjnie szuka takiego kodu, który po przekształceniu przez zamrożony generator z poprzedniego etapu w syntetyczny obraz MRI, zostanie najwyżej oceniony przez klasyfikator z etapu pierwszego. Klasyfikator dostarcza funkcję oceny, kierując procesem ewolucji w stronę generowania obrazu o pożądanym cechach. Wynikiem ewolucji jest wygenerowanie syntetycznego, a jednocześnie diagnostycznie wiarygodnego obrazu MRI konkretnego rodzaju schorzenia.

3 Konfiguracja eksperymentu

W Tabeli 1 przedstawiono wartości zmiennych wykorzystane w eksperymencie.

4 Analiza wyników

4.1 Klasyfikator

W pierwszym etapie wytrenowano sieć sieć splotową, której celem było wypracowanie stabilnej powierzchni decyzyjnej dla czterech klas obrazów MRI. Wykres zbieżności funkcji straty oraz dokładności na zbiorze testowym przedstawia Tabela 2. Wysoka dokładność klasyfikatora sprawiła, że stał się on bardzo wiarygodnym i wymagającym krytykiem dla algorytmu genetycznego w etapie 3.

W czasie treningu klasyfikatora błąd uczenia spadł o 81.6% w stosunku do epoki początkowej. Końcowa skuteczność generalizacji uśredniona dla wszystkich serii jest na poziomie 91.67%. Sieć poprawnie zidentyfikowała cechy poszczególnych guzów. Warto odnotować powtarzający się we wszystkich próbach chwilowy spadek dokładności w 6 epoce. Zjawisko to występuje niezależnie od losowej inicjalizacji wag i jego przyczyną jest najprawdopodobniej wejście optymalizatora w obszar trudniejszych próbek w jednym z pakietów danych. Zdolność sieci do natychmiastowego wyjścia z tego stanu w epoce 7 świadczy o dobrym doborze współczynnika uczenia.

4.2 DCGAN

Trening bezwarunkowego modelu DCGAN na 5000 obrazach MRI trwał 30 epok. Dla każdej z klas przebiegał on podobnie. W epoce 1 błąd generatora był bardzo wysoki ($L_G = 23.48$), podobnie jak błąd dyskryminatora ($L_D = 3.47$). Generator na początku generował czysty szum, który dyskryminator bez problemu odrzucał. Epoki 2–14 przyniosły szybką stabilizację. Błąd dyskryminatora spadł w okolice wartości 0.2 – 0.4, a błąd

Tabela 1: Konfiguracja eksperymentu

Parametr	Wartość	Opis
<i>Parametry globalne</i>		
SEED	42	Zapewnienie powtarzalności pseudowłaści środowiska
TARGET_CLASS	["glioma", "meningioma", "pituitary"]	Wybrane schorzenie docelowe dla optymalizacji
<i>Etap 1: Klasyfikator CNN</i>		
CLASSIFIER_EPOCHS	8	Liczba epok uczenia sieci klasyfikującej
LR	1×10^{-3}	Współczynnik uczenia optymalizatora Adam
BATCH_SIZE	64	Wielkość wsadu danych treningowych
<i>Etap 2: Model Generatywny (DCGAN)</i>		
GAN_EPOCHS	30	Liczba epok uczenia pary sieci GAN
LATENT_DIM	100	Wymiarowość wektora początkowego (z)
LR	2×10^{-4}	Współczynnik uczenia dla generatora i dyskriminatora
BETA1	0.5	Parametr pędu optymalizatora Adam
BATCH_SIZE	128	Wielkość wsadu danych dla sieci generatywnej
<i>Etap 3: Algorytm Genetyczny (GA)</i>		
num	60	Liczba osobników (wektorów z) w populacji ewolucyjnej
iterations	80	Liczba generacji (maksymalna liczba generacji GA)
bounds	(-3.0, 3.0)	Dopuszczalny zakres wartości dla poszczególnych wektorów z
selection	"tournament"	Metoda wyboru osobników do reprodukcji
crossover	"arithmetic"	Typ krzyżowania (kombinacja arytmetyczna rodziców)
pc	0.8	Prawdopodobieństwo zajścia odcinka krzyżowania
pm	0.1	Prawdopodobieństwo mutacji poszczególnego genu osobnika
sigma	0.3	Odchylenie standardowe szumu gaussowskiego mutacji
elitism	2	Liczba najlepszych osobników kopiowanych bez zmian

Tabela 2: Dynamika uczenia modelu klasyfikacyjnego na przestrzeni 8 epok

Epoka	Funkcja straty	Dokładność
1	0.9596	76.65% $\pm$ 0.3%
2	0.4957	76.97% $\pm$ 0.4%
3	0.3895	81.30% $\pm$ 0.8%
4	0.3096	85.60% $\pm$ 0.4%
5	0.2867	86.67% $\pm$ 0.2%
6	0.2674	80.17% $\pm$ 0.1%
7	0.2163	90.27% $\pm$ 0.2%
8	0.1763	91.67% $\pm$ 0.6%

generatora oscylował w granicach 4.5–7.5. Generator zaczął szybko uczyć się podstawowej struktury obrazów MRI, aby oszukać silniejszy dyskryminator. W niektórych późniejszych epokach widać wyraźne skoki, w których generator chwilowo zyskiwał przewagę, na co dyskryminator odpowiadał adaptacją w kolejnych epokach, sprowadzając błąd z powrotem w dół. Końcowe wartości to ($\text{loss_D} = 0.3542$, $\text{loss_G} = 3.4593$). Model nie doświadczył zjawiska całkowitego zapadnięcia trybów ani eksplozji gradientu. Sieć ustaliła równowagę.

4.3 Algorytm genetyczny

Kluczowym elementem eksperymentu była optymalizacja wektorów latentnych za pomocą algorytmu genetycznego dla trzech różnych klas docelowych. Zestawienie efektywności tego procesu prezentuje Tabela 3.

Tabela 3: Porównanie efektywności algorytmu genetycznego dla poszczególnych guzów

Klasa	Początkowe P	P w ostatniej iteracji	Iteracja nasycenia
<i>glioma</i> (glejak)	0.6993	1.0	20
<i>meningioma</i> (oponiak)	0.3998	1.0	20
<i>pituitary</i> (gruczolak)	0.1964	1.0	10


W celu weryfikacji, czy wysokie prawdopodobieństwa zwracane przez klasyfikator przekładają się na rzeczywiste wyniki utworzono zestawienie wygenerowanych serii obrazów (Rysunki 3, 4, 5). Na każdym z nich w górnym rzędzie znajduje się osiem obrazów z bezwarunkowego modelu DCGAN, a poniżej kopie tego samego obrazu wyewoluowanego algorytmem genetycznym.

4.3.1 Klasa glioma


Klasa ta charakteryzowała się najwyższym bazowym prawdopodobieństwem przy losowym próbkowaniu (69.93%). Bezwarunkowy GAN w naturalny sposób preferował generowanie cech bliskich glejakom. Algorytm genetyczny miał więc lepszy punkt startowy. Populacja potrzebowała 20 iteracji, aby dokonać precyzyjnej korekty genów i osiągnąć maksymalną możliwą wartość na poziomie $P = 1.0$.

4.3.2 Klasa meningioma


Wektor wyjściowy dla oponiaka przy losowym szumie osiągał istotnie niższą wartość początkową (39.98%). Cechy tej patologii, głównie guzy wyraźnie odgraniczone, były rzadsze




Rysunek 2: Wykres zbieżności algorytmu genetycznego dla klasy glioma



Rysunek 3: Zestawienie obrazów dla klasy glioma



Rysunek 4: Wykres zbieżności algorytmu genetycznego dla klasy meningioma



Rysunek 5: Zestawienie obrazów dla klasy meningioma


w rozkładzie bazowym sieci DCGAN. Mimo trudniejszego punktu startowego, operator krzyżowania arytmetycznego oraz selekcja turniejowa sprawnie poradziły sobie. W 10 iteracji algorytm osiągnął stan bliski doskonałości ($best_P = 0.9997$), a w 20 generacji nastąpiła pełna zbieżność populacji do wartości 1.0.

4.3.3 Klasa pituitary


Klasa ta stanowiła teoretycznie najtrudniejszy problem optymalizacyjny, gdyż losowe próbkowanie dawało zaledwie 19.64% szans na wygenerowanie cech tej patologii. Gruczolak przysadki wymaga specyficznej lokalizacji anatomicznej, znajduje się on u podstawy czaszki. Mimo niskich szans sukcesu, to właśnie dla tej klasy algorytm genetyczny wykazał największe tempo zbieżności. Już po 10 iteracjach zarówno najlepszy osobnik, jak i cała populacja ($mean_P = 1.0$) osiągnęły stan absolutnego nasycenia.

5 Wnioski

W tym eksperymencie istniało ryzyko, że algorytm genetyczny wygeneruje czysty szum, który oszuka klasyfikator matematycznie ale będzie nieczytelny dla człowieka. Na szczęście wygenerowane obrazy po zastosowaniu algorytmu genetycznego są w miarę czytelne anatomicznie. Posiadają wyraźne granice czaszki, zróżnicowanie tkanek i zachowaną fizyczną ciągłość kształtów. Połączenie bezwarunkowego modelu DCGAN i algorytmu



Rysunek 6: Wykres zbieżności algorytmu genetycznego dla klasy pituitary



Rysunek 7: Zestawienie obrazów dla klasy pituitary

genetycznego pozwala na sterowanie procesem generowania obrazów medycznych o ściśle zdefiniowanych cechach klinicznych. Eliminuje to potrzebę kosztownego i trudnego w stabilizacji treningu warunkowych sieci GAN. Jednakże osiągnięcie przez całą populację średniej wartości przystosowania równą 1.0 w tak wczesnych stadiach wskazuje na całkowitą utratę różnorodności genetycznej. Jest to wadą tej metody. Algorytm powiela tylko jednego najlepszego osobnika. Znalazł jedno optymalne rozwiązanie i przestał poszukiwać innych wariantów.